

Chủ đề: Dự đoán giá điện thoại bằng mô hình học máy

Nguyễn Cảnh Tùng - 23001950

Nguyễn Ngọc Tuấn - 23001948

Nguyễn Khánh Toàn - 23001944

Môn học: Học máy

Giảng viên hướng dẫn: TS. Cao Văn Chung

Trường Đại học Khoa học Tự nhiên - ĐHQG Hà Nội

Hà Nội, tháng 1 năm 2026

Nội dung chính

- 1 Giới thiệu bài toán và phương pháp
- 2 Tiền xử lí dữ liệu
- 3 Phân tích và trực quan hóa dữ liệu
- 4 Phân cụm dữ liệu
- 5 Kết quả thực nghiệm
- 6 Tổng kết

Giới thiệu bài toán

- **Mục tiêu:** Xây dựng mô hình dự đoán giá điện thoại dựa trên thông số kỹ thuật (RAM, pin, camera, bộ nhớ trong, bộ nhớ ngoài, v.v.).
- **Tầm quan trọng:** Hỗ trợ người tiêu dùng trong so sánh và lựa chọn cũng như giúp nhà bán lẻ định giá hợp lý sản phẩm mới.
- **Dữ liệu:** Sử dụng bộ dữ liệu 1359 mẫu từ Kaggle (thu thập từ Gadgets360). Dữ liệu có 21 trường, gồm 2 trường tên, 10 trường liên tục, 9 trường phân loại.

Phương pháp sử dụng

Các mô hình sử dụng

- Hồi quy: K-NN, Hồi quy tuyến tính
- Phân loại: Naive Bayes, Hồi quy SoftMax



Các phương pháp giảm chiều được sử dụng

- Phân tích thành phần chính (PCA)
- Phân tích phân biệt tuyến tính (LDA)

Các phương pháp phân cụm được sử dụng

- K-trung bình (K-means)
- DBSCAN
- GMM (thuật toán cực đại hóa kì vọng)

Xử lý biến mục tiêu



Hình: 1. Biểu đồ phân bố giá gốc (Price)



Vấn đề: Phân bố giá bị lệch phải

- Hầu hết điện thoại có giá rẻ, tập trung ở bên trái.
- Một vài mẫu giá rất cao kéo đuôi đồ thị về bên phải.
- Gây ảnh hưởng xấu đến các mô hình như Hồi quy Tuyến tính.

Xử lý biến mục tiêu


Giải pháp: Log-transform

- Áp dụng $Price_log = \log(1 + Price)$.
- Đưa phân bố giá về dạng gần chuẩn.
- Giúp mô hình Linear Regression hoạt động tốt hơn.
- Loại bỏ các giá trị ngoại lai ($z\text{-score} \geq 3$), những giá trị lớn hơn giá trị trung bình 3 lần độ lệch chuẩn.



Hình: 2. Biểu đồ phân bố giá sau khi Log Transform

Xử lý đặc trưng



Hình: 3. Biểu đồ phân bố một số trường phân loại

Xử lí đặc trưng

- **Loại bỏ đặc trưng:**

- 'Name', 'Model': Không mang thông tin kỹ thuật hoặc quá nhiều giá trị.
- 'Touchscreen', 'Wi-Fi', 'Bluetooth', 'GPS', '3G': Quá lệch (hơn 95% là 'Yes').

Xử lí đặc trưng

- **Loại bỏ đặc trưng:**

- 'Name', 'Model': Không mang thông tin kỹ thuật hoặc quá nhiều giá trị.
- 'Touchscreen', 'Wi-Fi', 'Bluetooth', 'GPS', '3G': Quá lệch (hơn 95% là 'Yes').

- **Mã hóa và Gom nhóm:**

- **OS:** Gom thành 3 nhóm 'Android', 'iOS', 'Other'.
- **Processor:** Gom thành 3 nhóm '1_2', '4_6', '8_10' (số nhân).
- Áp dụng **One-Hot Encoding** cho các biến phân loại, bao gồm cả trường 'Brand'.

Các trường sau khi tiền xử lý

Biến số (liên tục):


- Battery capacity
- Screen size
- Resolution x
- Resolution y
- Storage
- Rear camera
- Front camera
- RAM
- Price_log

Biến nhị phân / One-hot:

- SIM_2
- 4G_Yes
- CPU_4_6
- CPU_8_10
- OSs_Other
- OSs_iOS
- Các biến liên quan đến hãng sản xuất: Brand_Asus, Brand_BlackBerry, ...


Phân tích với PCA (Phương sai giải thích)

- **Mục tiêu PCA:** Giảm số chiều dữ liệu, loại bỏ nhiễu, giữ lại thông tin quan trọng (phương sai), giúp mô hình học hiệu quả và ổn định hơn.



Hình: 3. Biểu đồ phương sai giải thích của PCA

Phân tích với PCA (Phương sai giải thích)




Hình: 3. Biểu đồ phương sai giải thích của PCA

- **Phát hiện 1:** Thành phần chính thứ nhất (PC1) chiếm ưu thế vượt trội, giải thích **~65%** tổng phương sai.
- **Phát hiện 2:** 4 thành phần chính đầu tiên giải thích **>85%** tổng phương sai.


Phân tích với PCA (Trực quan)

Các điểm dữ liệu được phân bố tương đối đồng đều, không xuất hiện cụm rõ rệt, cho thấy rằng các thành phần chính (PC1–PC4) đã nắm bắt được phần lớn phương sai trong dữ liệu mà không có sự chồng chéo mạnh giữa các chiều.



Hình: 4. Trực quan theo từng cặp thành phần chính


Phân tích PCA (Tương quan với đầu ra)




Hình: 5. Mối quan hệ giữa PC1, PC2 và Price_log

Phát hiện: Khi PC1 tăng (từ -4 đến 8), màu sắc chuyển từ tím (giá thấp) sang vàng (giá cao). $\Rightarrow$ **PC1 nắm bắt được tín hiệu chính của giá.**

Phân tích PCA (Tương quan với đầu ra)



Hình: 5. Mối quan hệ giữa PC1, PC2 và Price_log



Hình: 6. Mối quan hệ giữa PC3, PC4 và Price_log

Phát hiện: Khi PC1 tăng (từ -4 đến 8), màu sắc chuyển từ tím (giá thấp) sang vàng (giá cao). $\Rightarrow$ **PC1 nắm bắt được tín hiệu chính của giá.**


Phát hiện: Các điểm màu phân bố ngẫu nhiên, không có xu hướng rõ rệt. $\Rightarrow$ **PC3 và PC4 dường như chỉ nắm bắt nhiễu (noise).**

Phân tích LDA

- **Mục tiêu:** Giảm số chiều dữ liệu, nhưng tăng khả năng phân tách của các lớp.
- LDA chỉ hoạt động khi đầu ra là biến phân loại, không phải giá trị liên tục. Vì đầu ra là biến liên tục, ta cần phân nhóm giá để LDA có thể dùng được.
=> **Chia thành 5 nhóm theo phân vị:** ['Very Low', 'Low', 'Medium', 'High', 'Very High']


Phân tích LDA (Trực quan)

Trục LD1 thể hiện khả năng phân biệt rõ nhất giữa các mức giá — ngụ ý rằng LD1 nắm giữ hầu hết thông tin phân loại. Các thành phần LD2–LD4 không thể hiện sự phân tách rõ ràng như LD1.



Hình: 7. Biểu đồ phân tán thành phần chính


Phân tích LDA (Khả năng phân tách)



Hình: 8. Khả năng tách phân lớp của LDA

Phát hiện 1: Thành phần LD1 chiếm $\sim 85\%$ tổng khả năng phân tách

Phân tích với LDA (Tương quan với đầu ra)




Hình: 9. Mối quan hệ giữa LD1, LD2 và Price_log

Phát hiện 2: Tương tự như PCA, LD1 có **tương quan tuyến tính** khá với Price_log.

DBScan - Chọn chỉ số hợp lí

Lựa chọn ϵ hợp lí: dựa vào biểu đồ k-distance. Thường chọn các giá trị tại đó đồ thị uốn nhiều nhất.



Hình: 10. Đồ thị k-distance (MinPts = 10).


DBScan - Kết quả phân cụm

Bảng: Tổng hợp kết quả thực nghiệm tham số DBSCAN

MinPts	Eps (ϵ)	Số cụm	Nhiều	Silhouette
5	2.0	4	60	0.3525
	2.2	3	37	0.4330
	2.5	1	23	-
	2.8	1	14	-
10	2.2	3	61	0.3841
	2.5	2	25	0.4618
	2.8	1	14	-
	3.0	1	13	-
15	2.2	1	99	-
	2.5	2	39	0.4545
	2.8	1	17	-
	3.0	1	13	-
20	2.2	1	110	-
	2.5	1	68	-
	2.8	1	21	-
	3.0	1	14	-


DBScan - Phân bố

Cụm 0 đại diện cho nhóm mức giá trung bình. Cụm 1 đại diện cho mức giá cao hơn. Cụm -1 (nhiều) có phân bố rộng.



Hình: 11. Phân bố giá thành trong các cụm tìm được


DBScan - Trực quan



Hình: 12. Trực quan hóa các cụm

Cụm 0 với chiếm phần lớn. Cụm 1 tạo thành 1 nhóm nhỏ riêng biệt. Nhiều nằm rải rác.


KMeans - Chọn k tối ưu bằng Silhouette Score



Hình: 13. Silhouette Score tương ứng với các giá trị k


KMeans - Kết quả đầu ra

Phân bố giá giữa 2 cụm có sự khác biệt, cho thấy phân cụm đạt hiệu suất khá tốt.




Hình: 16. Phân phối giá trong các cụm

KMeans - Trực quan hóa




Hình: 17. Trực quan hóa các cụm

GMM - Lựa chọn số cụm tối ưu



Hình: 18. Chỉ số BIC với k tương ứng.

GMM - Kết quả




Hình: 19. Phân bố giá ứng với từng cụm.

Mức giá trung bình khá tương đồng giữa các cụm.

GMM - Trực quan

Các điểm dữ liệu thuộc cùng một cụm có xu hướng tập trung gần nhau, phản ánh đúng cấu trúc phân khúc của thị trường điện thoại.



Hình: 20. Trực quan hóa các cụm.

Kết quả mô hình KNN

(a) Dữ liệu gốc

Tỉ lệ Train:Test	Train			Test		
	MSE	R^2	MAE	MSE	R^2	MAE
4:1	0.1605	0.6884	0.2971	0.2408	0.5783	0.3655
7:3	0.1565	0.7026	0.2933	0.2157	0.5895	0.3459
6:4	0.1872	0.6399	0.3189	0.2196	0.5900	0.3441

- R^2_{train} : 0.64 – 0.70
- R^2_{test} : 0.58 – 0.59
- Chênh lệch khoảng 0.1 giữa train và test.
- Có hiện tượng **overfitting nhẹ**.

Kết quả mô hình KNN

(b) Dữ liệu giảm còn 6 chiều (PCA)

Tỉ lệ Train:Test	Train			Test		
	MSE	R^2	MAE	MSE	R^2	MAE
4:1	0.1827	0.6453	0.3151	0.2443	0.5722	0.3732
7:3	0.1953	0.6288	0.3234	0.2131	0.5945	0.3504
6:4	0.1948	0.6254	0.3248	0.2234	0.5830	0.3511

- PCA giảm còn 6 chiều cho kết quả **ổn định** với $R^2_{test} \approx 0.57 - 0.59$.
- Độ chênh lệch giữa train và test giảm $\approx 0.03 - 0.05 \rightarrow$ **giảm overfitting** so với dữ liệu gốc.
- MSE và MAE tăng nhẹ, cho thấy việc giảm chiều làm mất một phần thông tin.
- Tỉ lệ 7:3 đạt hiệu suất tốt nhất: $R^2_{test} = 0.5945$.

Kết quả mô hình KNN

(c) Dữ liệu giảm còn 4 chiều (PCA)

Tỉ lệ Train:Test	Train			Test		
	MSE	R^2	MAE	MSE	R^2	MAE
4:1	0.1808	0.6490	0.3116	0.2364	0.5860	0.3741
7:3	0.2029	0.6145	0.3305	0.2264	0.5692	0.3620
6:4	0.2078	0.6004	0.3356	0.2373	0.5570	0.3614

- PCA giảm còn 4 chiều làm **hiệu suất suy giảm nhẹ**: R^2_{test} chỉ còn 0.55–0.59.
- Khoảng cách R^2 giữa train và test vẫn ở mức nhỏ (0.04) $\rightarrow$ mô hình **ít overfitting**.
- MSE/MAE tăng hơn so với PCA-6D, cho thấy mất nhiều thông tin hơn khi giảm chiều.
- Tỉ lệ 4:1 cho kết quả tốt nhất: $R^2_{\text{test}} = 0.5860$.

Hệ số chệch là bắt buộc!

Thử nghiệm mô hình HQTТ trên tập dữ liệu gốc với tỉ lệ train:test là 4:1, thu được kết quả sau:

- **Mô hình có hệ số chệch (bias):**

- Train: $R^2 = 0.6349$, $MSE = 0.1881$
- Test: $R^2 = 0.6131$, $MSE = 0.2209$
- **Hiệu suất tốt, ổn định giữa train và test**

- **Mô hình không có hệ số chệch (bias):**

- Train: $R^2 = -0.9581$
- Test: $R^2 = -0.5804$
- **Hiệu suất rất kém — mô hình không phù hợp**

- **Kết luận:** Cần sử dụng mô hình **có hệ số chệch (bias)** để mô tả dữ liệu đúng và đạt hiệu quả dự đoán tốt.

Kết quả mô hình HQT

(a) Dữ liệu gốc

Tỉ lệ Train:Test	Train			Test		
	MSE	R^2	MAE	MSE	R^2	MAE
4:1	0.1881	0.6349	0.3238	0.2209	0.6131	0.3571
7:3	0.1943	0.6308	0.3279	0.1964	0.6262	0.3391
6:4	0.1899	0.6348	0.3234	0.2035	0.6200	0.3394

- Khoảng cách R^2 giữa tập train và test giữa các kịch bản thấp => **Hiện tượng overfitting rất nhẹ.**
- R^2 trên tập test có giá trị trung bình cao hơn mô hình K-NN với dữ liệu gốc, cho thấy mô hình HQT có thể tốt hơn.
- Như K-NN, tỉ lệ 7:3 cho hiệu suất tốt nhất $R^2 = 0.6262$. Đây cũng là hiệu suất cao nhất trong tất cả kịch bản.

Kết quả mô hình HQT

(b) Dữ liệu giảm còn 4 chiều (PCA)

Tỉ lệ Train:Test	Train			Test		
	MSE	R^2	MAE	MSE	R^2	MAE
4:1	0.2176	0.5775	0.3463	0.2457	0.5698	0.3810
7:3	0.2240	0.5743	0.3515	0.2206	0.5802	0.3596
6:4	0.2174	0.5819	0.3466	0.2304	0.5699	0.3592

- PCA giảm còn 4 chiều đã khiến hiệu suất giảm rõ rệt: $R^2_{test} = 0.5802$ ở trường hợp cao nhất, chỉ ngang K-NN.
- Bên cạnh đó, các giá trị MSE, MAE tăng nhẹ, cho thấy sự mất mát thông tin khi giảm chiều.

Kết quả mô hình HQT

(c) Dữ liệu giảm còn 6 chiều (PCA)

Tỉ lệ Train:Test	Train			Test		
	MSE	R^2	MAE	MSE	R^2	MAE
4:1	0.2115	0.5895	0.3418	0.2419	0.5764	0.3755
7:3	0.2188	0.5843	0.3470	0.2143	0.5921	0.3542
6:4	0.2117	0.5929	0.3420	0.2263	0.5775	0.3556

- PCA giảm xuống 6 chiều cũng không cải thiện hiệu suất hơn trường hợp 4 chiều
- Hiệu suất tốt nhất $R_{test}^2 = 0.5921$, không cải thiện nhiều so với 4 chiều và tệ hơn dữ liệu gốc.

So sánh hai mô hình: Linear Regression vs KNN

- **Hiệu suất tổng thể:**

- Linear Regression đạt R^2_{test} cao nhất (0.626) → **mô hình tốt nhất**.

- **Độ ổn định (Overfitting):**

- Linear Regression rất ổn định, gần như không overfitting.
- KNN bị overfit rõ rệt hơn trên dữ liệu gốc.

- **Ảnh hưởng của PCA:**

- PCA **giảm hiệu suất** của Linear Regression (mất bớt thông tin).
- PCA **giảm overfitting** cho KNN nhưng **không cải thiện R^2** .

- **Kết luận** Kịch bản tốt nhất đạt được cho bài toán này là Mô hình hồi quy tuyến tính trên dữ liệu gốc với kịch bản Train:Test = 7:3

Phân tích mô hình tốt nhất

Bảng hệ số của mô hình

Hệ số	Giá trị
β_0 (intercept)	4.6347
β (Screen size)	0.0126
β (Resolution x)	0.1454
β (Resolution y)	0.1492
β (Storage)	0.0789
β (Rear camera)	0.0534
β (Front camera)	-0.0666
β (RAM)	0.2079
β (Battery)	0.0134
β (SIM_2)	-0.1873
β (4G_Yes)	0.0161
β (CPU_4_6)	-0.0205
β (CPU_8_10)	-0.0122
β (OSs_Other)	0.2891
β (OSs_iOS)	1.2555

Nhận xét chính:

- Hệ số **intercept** = **4.63** thể hiện mức giá nền (theo log-price).
- **iOS** có hệ số lớn nhất $\rightarrow$ iPhone có giá cao vượt trội.
- **RAM** và **Resolution** ảnh hưởng mạnh nhất trong nhóm thông số kỹ thuật.
- **SIM_2** và **Camera trước** có hệ số âm $\rightarrow$ thường xuất hiện ở điện thoại tầm trung.

Kết quả mô hình hồi quy SoftMax

Note: Cần chuẩn hóa dữ liệu trước khi đưa vào mô hình.

Bảng: Kết quả độ chính xác (Accuracy) mô hình Softmax Regression

Đầu ra	Tỷ lệ (Train:Test)	Độ chính xác (Accuracy)		Chênh lệch
		Original (46 chiều)	PCA (15 chiều)	
3 Khoảng	6 : 4	0.6704	0.6556	0.0148
	7 : 3	0.6716	0.6691	0.0025
	8 : 2	0.6593	0.6407	0.0186
4 Khoảng	6 : 4	0.5667	0.5407	0.0260
	7 : 3	0.5926	0.5778	0.0148
	8 : 2	0.5889	0.5815	0.0074

- Tỷ lệ 7:3 cho kết quả tốt nhất ở cả bài toán 3 nhãn và 4 nhãn.
- Chênh lệch về accuracy giữa các kịch bản với bộ dữ liệu gốc và đã giảm chiều là **không lớn**.

Kết quả mô hình Naive Bayes

Dữ liệu có cả trường liên tục và trường phân loại, nên áp dụng cả Gaussian NB và Bernoulli NB (cho dữ liệu gốc, dữ liệu đã giảm chiều chỉ áp dụng GNB).

Bảng: Kết quả độ chính xác (Accuracy) mô hình Naive Bayes

Đầu ra	Tỷ lệ (Train:Test)	Độ chính xác (Accuracy)		Chênh lệch
		Original (46 chiều)	PCA (15 chiều)	
3 Khoảng	6 : 4	0.6185	0.7130	-0.0945
	7 : 3	0.6025	0.7012	-0.0987
	8 : 2	0.5889	0.6963	-0.1074
4 Khoảng	6 : 4	0.5222	0.6037	-0.0815
	7 : 3	0.5259	0.6222	-0.0963
	8 : 2	0.5259	0.6704	-0.1445

- Khác với HQ SoftMax, giảm chiều dữ liệu cho ra accuracy **cao hơn!**
- Kết quả cho ra **tốt hơn** Softmax khi đã giảm chiều, **tệ hơn** khi chưa giảm chiều.

Tổng kết

- Đã xây dựng thành công mô hình Hồi quy Tuyến tính để dự đoán giá điện thoại với $R^2_{test} \approx 0.626$. Mô hình KNN cho hiệu suất thấp hơn, overfit nặng hơn HQT.
- Mô hình ổn định, ít overfit, và các giả định được kiểm chứng (qua phân tích phần dư).
- Các yếu tố ảnh hưởng mạnh nhất đến giá là: **Hệ điều hành (iOS), RAM, và Độ phân giải.**

Tổng kết

- Đã xây dựng thành công mô hình Hồi quy Tuyến tính để dự đoán giá điện thoại với $R^2_{test} \approx 0.626$. Mô hình KNN cho hiệu suất thấp hơn, overfit nặng hơn HQT.
- Mô hình ổn định, ít overfit, và các giả định được kiểm chứng (qua phân tích phần dư).
- Các yếu tố ảnh hưởng mạnh nhất đến giá là: **Hệ điều hành (iOS), RAM, và Độ phân giải.**
- $R^2 \approx 63\%$ là tốt, nhưng vẫn còn $\sim 37\%$ phương sai chưa giải thích được.
- Mối quan hệ còn lại có thể là **phi tuyến (non-linear)**.

Tổng kết

- Đã phân cụm được dữ liệu qua các phương pháp **K trung bình**, **GMM**, và **DBSCAN** với số cụm tốt nhất lần lượt là 2,7,2.
- Đã chia được đầu ra thành 3 hoặc 4 khoảng để chuyển bài toán về bài toán phân loại.
- Đã thực hiện thành công các mô hình phân loại **Naive Bayes** và **SoftMax**, mô hình **Naive Bayes** cho ra kết quả **tốt nhất** với $\text{accuracy} = 0.7130$.

Hết